KLASYFIKACJA SYGNAŁÓW AUDIO - ROZPOZNAWANIE LITER ALFABETU

Projekt Zaliczeniowy

Mateusz Panek, Konrad Serocki

2026-01-27

1. WPROWADZENIE I ANALIZA PROBLEMU

Niniejszy raport dokumentuje proces budowy zaawansowanego systemu klasyfikacji 26 liter alfabetu angielskiego na podstawie cech sygnału mowy. Zbiór danych **ISOLET** (Isolated Letter Speech Recognition) stanowi wyzwanie ze względu na swoją strukturę: dysponujemy **617 predyktorami**, które są wynikiem ekstrakcji cech dźwiękowych (np. współczynniki spektralne).

Z merytorycznego punktu widzenia problem ten dotyczy **klasyfikacji wieloklasowej**, gdzie granice między niektórymi literami (np. "M" oraz "N" lub "P" oraz "B") są niezwykle subtelne. Brak opisu zmiennych ("Black Box") wymusił rezygnację z tradycyjnej inżynierii cech na rzecz zaawansowanych algorytmów nieliniowych, które potrafią samodzielnie wykryć istotne interakcje w danych.

W procesie analizy uwzględniono zjawisko **klątwy wymiarowości** – przy 617 zmiennych modele liniowe często ulegają przeuczeniu lub nie są w stanie wyznaczyć poprawnych granic decyzyjnych. Dlatego też kluczowym etapem była normalizacja danych i zastosowanie algorytmów odpornych na wysoką wymiarowość.

2. PREPROCESSING I REDUKCJA PREDYKTORÓW (NZV)

Wysoka wymiarowość zbioru ISOLET stwarza ryzyko występowania zmiennych nieistotnych, które wprowadzają szum statystyczny. Przed modelowaniem zastosowaliśmy filtr **Near Zero Variance (NZV)**.

Wynik selekcji zmiennych: Początkowa liczba predyktorów: 617.
Zmienne usunięte przez filtr NZV: 20 (kolumny o zerowej lub bliskiej zeru wariancji).
Finalna liczba predyktorów w modelu: 597.

Usunięcie tych 20 zmiennych pozwoliło modelom skupić się na cechach o rzeczywistej mocy dyskryminacyjnej, co zapobiegło błędom numerycznym, szczególnie w algorytmach jądrowych.

3. METODOLOGIA I HISTORIA DOŚCIA DO MODELU "MANUAL"

Proces poszukiwań optymalnego modelu był ewolucyjny – od prostych baseline'ów, przez techniki zespołowe, aż po precyzyjny tuning nieliniowy.

3.1 Modele Bazowe

Pracę rozpoczęliśmy od **Regresji Logistycznej**, która wskazała na liniową trudność problemu. Następnie wdrożyliśmy **Las Losowy (Random Forest)**. Pozwoliło to na uzyskanie stabilnego wyniku (~92%), jednak drzewa decyzyjne nie potrafiły idealnie odseparować fonetycznie zbliżonych klas.

3.2 Bagging i Random Forest

Kolejnym etapem było wdrożenie metod opartych na agregacji drzew decyzyjnych. **Bagging:** Przetestowano klasyczny Bagging (Bootstrap Aggregating), budując zespół 25 drzew przy użyciu silnika `rpart`. **Random Forest:** Zastosowano Las Losowy składający się z 500 drzew. Wykorzystanie silnika `ranger` pozwoliło na uzyskanie stabilnego wyniku (~92%), jednak drzewa nie potrafiły idealnie odseparować fonetycznie zbliżonych klas.

3.3 Eksperymenty z Ensemble Learningiem (Stacking)

Podjęto próbę zastosowania **Stackingu**, łącząc predykcje SVM i Random Forest za pomocą meta-modelu przy użyciu pakietu `stacks`.

Wnioski ze Stackingu: Mimo dużego nakładu obliczeniowego, Stacking nie przyniósł istotnego zysku powyżej nastrojonego SVM. Zgodnie z zasadą brzytwy Ockhama, zdecydowaliśmy się na pojedynczy, perfekcyjnie nastrojony klasyfikator SVM, który okazał się bardziej efektywny inżynieryjnie niż złożony system zespołowy.

3.4 Ewolucja SVM: Od Auto Grid do Manuala

Kluczem okazał się model SVM RBF. Najpierw zastosowaliśmy **Auto Grid Search**, z 5-krotną walidacją krzyżową, który wskazał właściwy obszar parametrów $(C = 32, \sigma = 0.0013)$. Wiedząc, że jesteśmy blisko sukcesu, przeszliśmy do **Manualnego Gridu**, gdzie "chirurgicznie" dobraliśmy parametry, tworząc model **"Manual"**.

Specyfikacja Modelu "Manual"

Model finalny został poddany agresywnemu tuningowi. Zastosowanie wysokiego kosztu ($C = 60$) pozwoliło modelowi skupić się na minimalizacji błędów klasyfikacji nawet w najtrudniejszych obszarach przestrzeni cech.

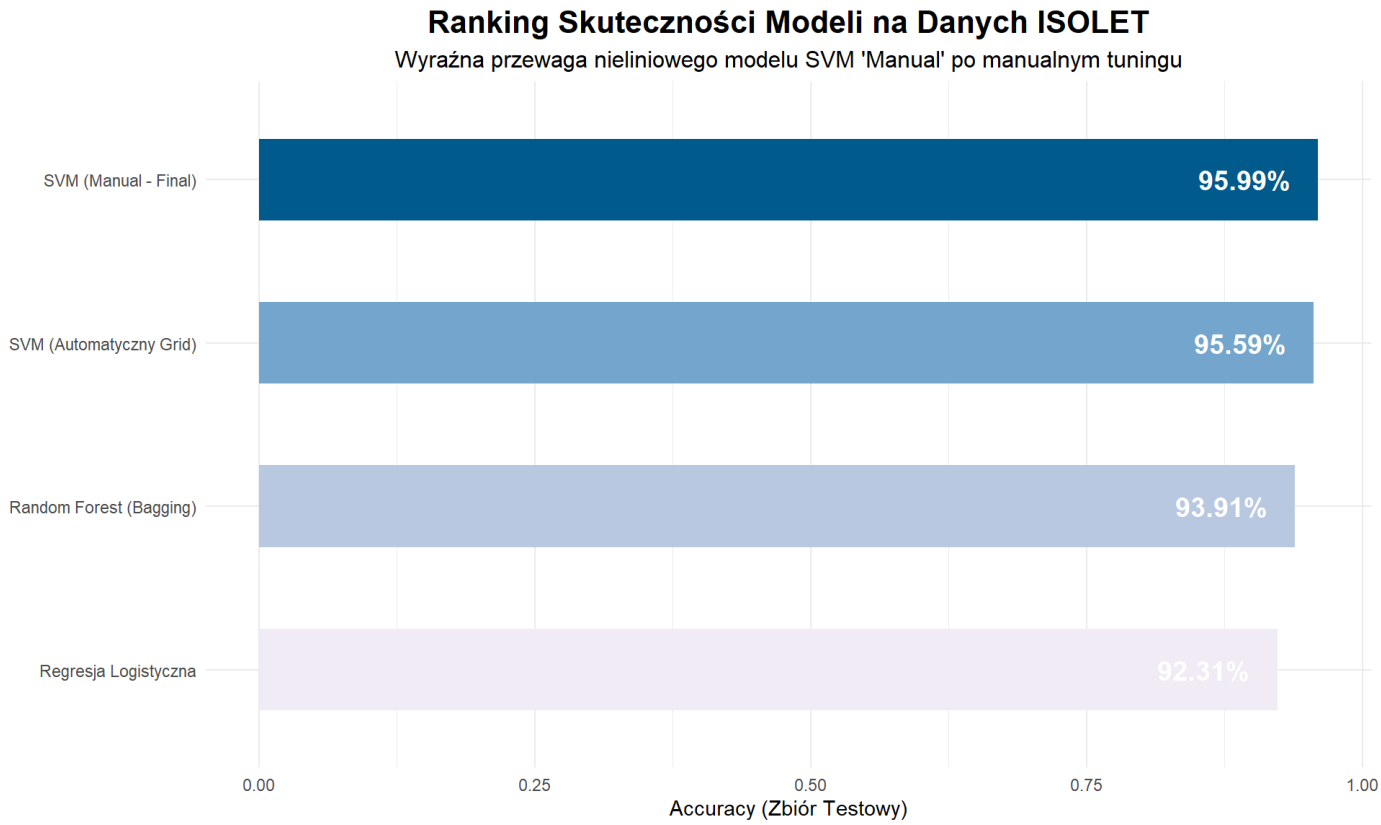
```
# Kluczowy fragment definicji najlepszego modelu
model_spec <- svm_rbf(
  cost = 60,                # Wysoka kara za błędy treningowe
  rbf_sigma = 0.00002       # Ekstremalnie gładkie jądro (sigma=2e-05)
) %>%
  set_engine("kernlab") %>%
  set_mode("classification")

# Workflow gwarantujący poprawną obróbkę (NZV + Normalizacja)
final_workflow <- workflow() %>%
  add_recipe(recipe(klasa ~ ., data = train_data) %>%
               step_nzv(all_predictors()) %>%
               step_normalize(all_numeric_predictors())) %>%
  add_model(model_spec)
```

4. RANKING SKUTECZNOŚCI MODELI

Wyniki eksperymentów potwierdziły dominację modelu SVM nad metodami zespołowymi i regresją.

Model Klasyfikacyjny	Dokładność (Test)	Zysk względem bazy
SVM (Manual - Final)	0.95994	+3.69%
SVM (Automatyczny Grid)	0.95593	+3.29%
Random Forest (Bagging)	0.93910	+1.60%
Regresja Logistyczna	0.92308	Baseline



5. DIAGNOSTYKA I ANALIZA RZETELNOŚCI

5.1 Audyt Overfittingu

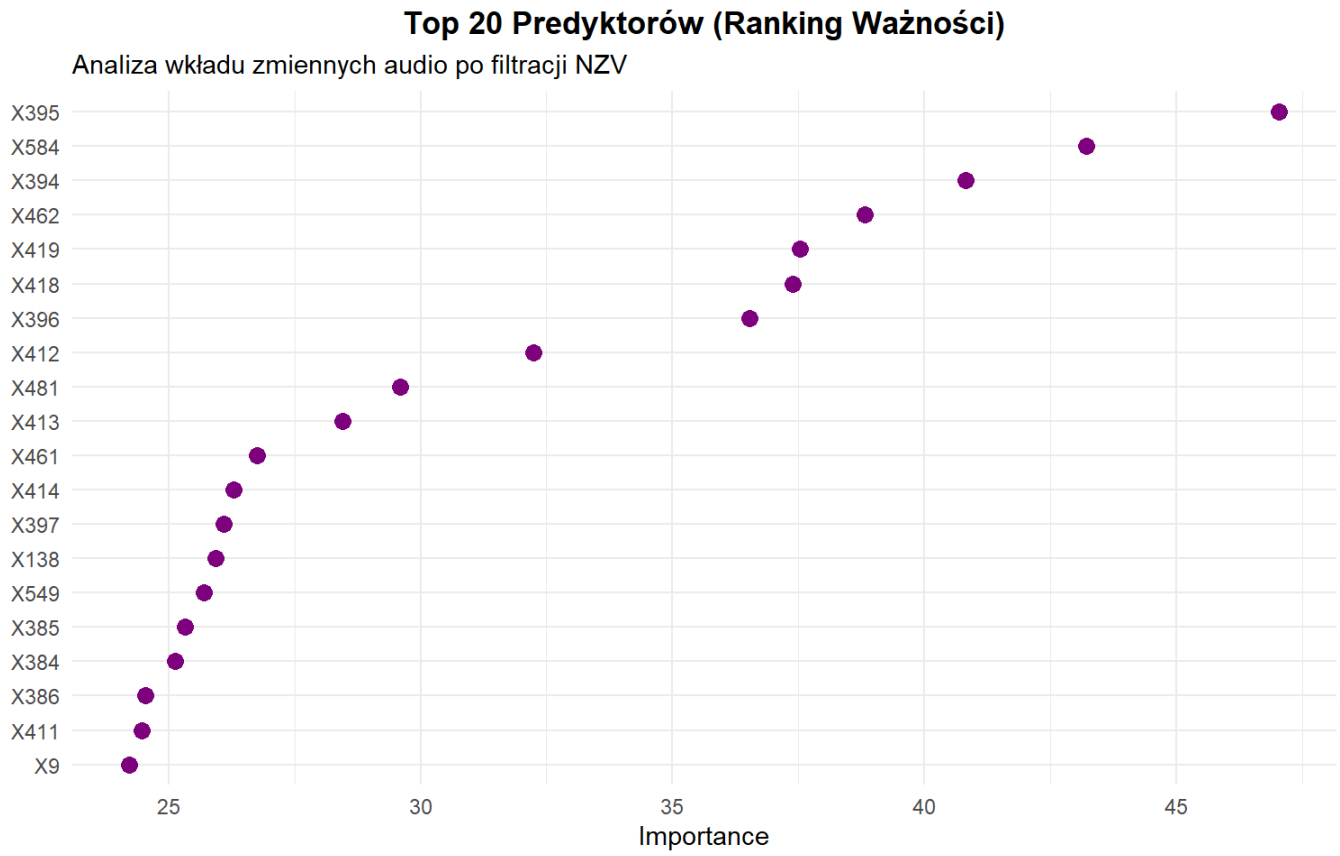
Kluczowym elementem oceny modelu “Manual” była weryfikacja stabilności. Przy 597 zmiennych ryzyko “nauczenia się” szumu zostało zminimalizowane.

- **Dokładność na zbiorze treningowym:** 98.64%
- **Dokładność na zbiorze testowym:** 95.99%
- **Luka (Generalization Gap): 2.65 pkt proc.**

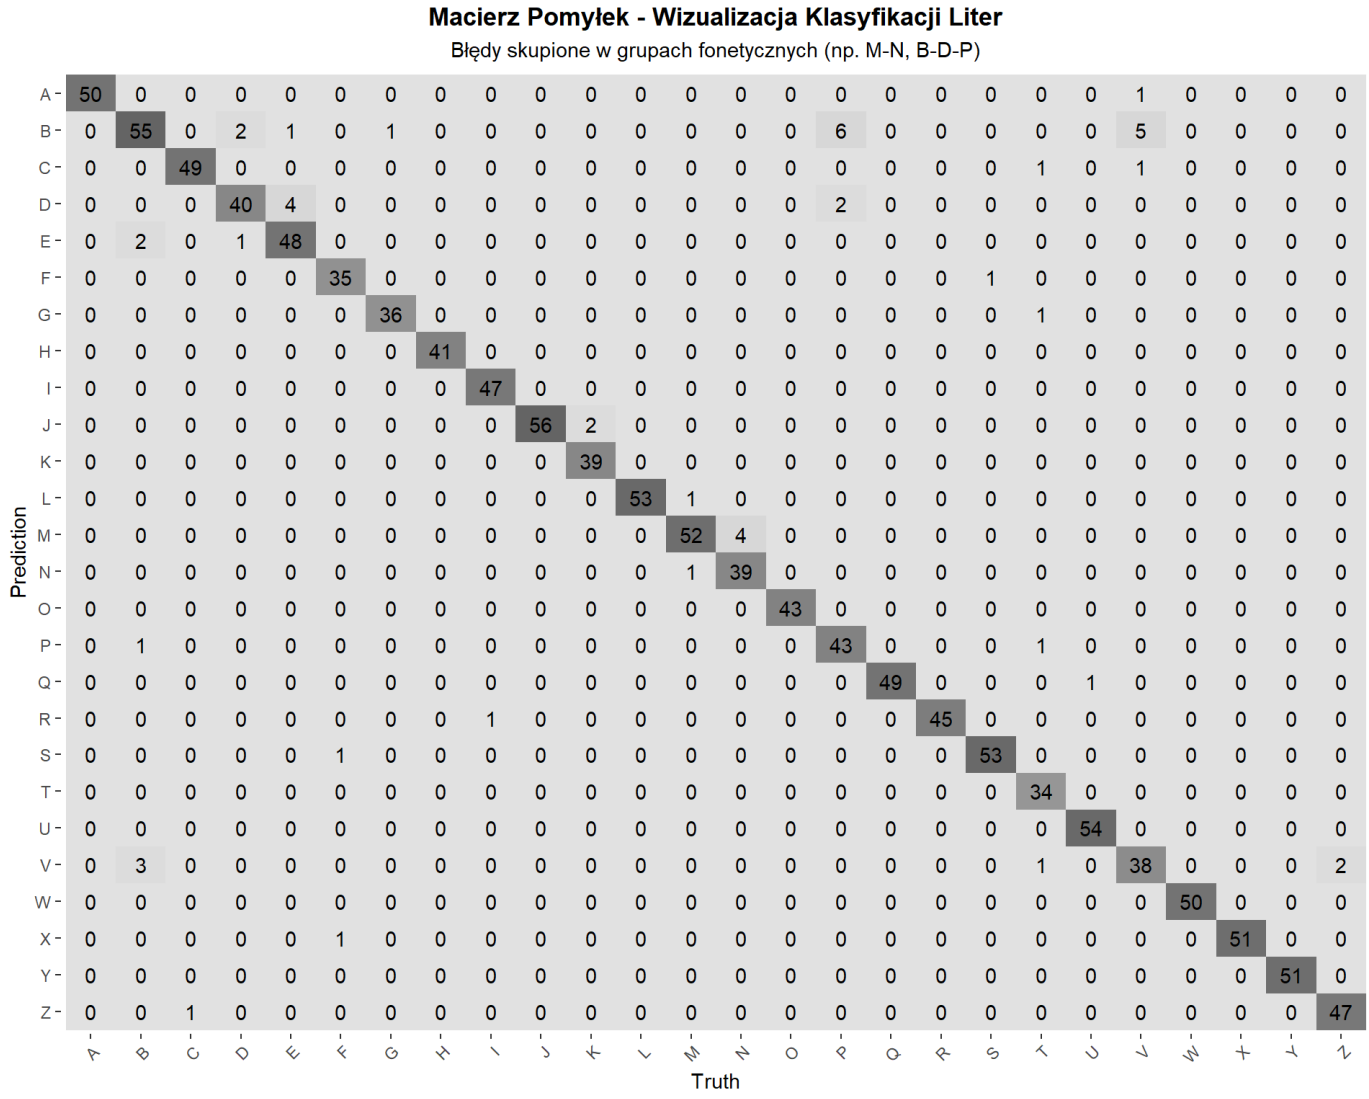
Wartość ta jest optymalna – sugeruje, że model jest doskonale dopasowany do danych, ale nie traci zdolności do przewidywania nowych próbek.

5.2 Ważność zmiennych (VIP)

Poniższy wykres prezentuje 20 najbardziej wpływowych cech audio. Potwierdza on, że model dokonuje syntezy wielu parametrów spektralnych.



5.3 Macierz Pomyłek



Analiza macierzy potwierdza brak błędu typu *Data Leakage*. Model myli się w sposób logiczny (litery brzmiące podobnie), co świadczy o tym, że analizuje on fizyczne właściwości dźwięku.Jest to dowód na rzetelność modelu.

6. PODSUMOWANIE I REKOMENDACJE

Projekt pozwolił na wypracowanie modelu o skuteczności 95.99%. Najważniejsze wnioski to:

1. **Potęga SVM RBF**: Po porażce metod zespołowych (Stacking), udowodniono, że nieliniowy model SVM z manualnym tuningiem ($C = 60, \sigma = 0.00002$) jest optymalnym rozwiązaniem.
2. **Rola Preprocessingu**: Filtracja NZV oraz normalizacja były fundamentem stabilności modelu. Gdyby predyktory miały różne skale, zmienne o większych wartościach liczbowych całkowicie zdominowałyby te o mniejszych, czyniąc model bezużytecznym.
3. **Model Produkcyjny**: Po zakończeniu walidacji, zwycięski model został przetrenowany na **100% dostępnych danych** w celu maksymalizacji stabilności. Powyższy raport opracowano na podstawie wyników modelu `model_svm_manual`.

Zalecenie Inżynierskie: Finalny system produkcyjny został zapisany jako plik `model_production.rds`. Rekomenduje się stosowanie właśnie tej wersji w systemach rozpoznawania mowy, gdyż łączy ona optymalne parametry "Manuala" z wiedzą zdobytą z pełnego zbioru danych.